

Modélisation et identification causale

Séance 4 – Pourquoi contrôler les facteurs confondants ?

Pierre Pora

2022-11-29

“Il faudrait contrôler de etc.”

- ▶ **Cette semaine :**

- ▶ Qu'est-ce que cela signifie exactement ?
- ▶ Pourquoi faut-il le faire ?
- ▶ Comment sait-on de quoi il faut contrôler ?

- ▶ **La semaine prochaine**

- ▶ Comment fait-on au juste pour contrôler ?

- ▶ **Deux questions très différentes**

- ▶ La première se passe en fait totalement de données !
- ▶ La seconde y fait lourdement appel

Manipuler quelques concepts de causalité


La France comptait 67 millions d'habitants en 2018

- Est-ce une **proposition causale** ?

La France comptait 67 millions d'habitants en 2018

- ▶ Est-ce une **proposition causale** ?
- ▶ Non : **une proposition causale est une comparaison**

La comparaison faite dans ce graphique (Piketty (2019)) est-elle une proposition causale ?



La comparaison faite dans ce graphique est-elle une proposition causale ?

- ▶ Non : **une proposition causale compare des situations dont au moins une est hypothétique / contrefactuelle**

Une tentative de définition

Une **proposition causale** est une proposition qui **compare** la situation d'**entités homologues** entre plusieurs **mondes possibles** différents résultant d'une certaine **variation contrefactuelle**. Sa forme typique est : *si le monde différait du monde observé de telle ou telle façon, alors tel aspect s'en trouverait également changé.*

Problème fondamental de l'inférence causale (Holland (1986))

- ▶ Le monde hypothétique que l'on cherche à comparer au monde observé n'est *jamais* observé
- ▶ Les effets causaux **ne peuvent pas** être des résultats simples de la collecte de données sur le monde observé
 - ▶ Collecter davantage de données, ou de meilleures données n'y changera rien

Modèle causal de Neyman-Rubin (Splawa-Neyman, Dabrowska, and Speed (1990); Rubin (1974)) : la population

- ▶ Modèle issu de la **statistique agricole**, arrivé en sciences sociales en particulier par analogie avec les **sciences médicales**
- ▶ On a une **population d'individus** qu'on peut indexer par i allant de 1 à N
 - ▶ Pour la statistique agricole : des parcelles
 - ▶ Pour les sciences médicales : des patients
 - ▶ Pour les sciences sociales : ce qu'on veut selon le problème que l'on traite → des êtres humains, des zones géographiques, des objets, des organisations. . .

Modèle causal de Neyman-Rubin (Splawa-Neyman, Dabrowska, and Speed (1990); Rubin (1974)) : l'intervention

- ▶ **Conception interventionniste de la causalité** : on veut connaître les effets d'une intervention, c'est-à-dire d'une manipulation possible du monde
- ▶ Cas simple, potentiellement généralisable : **l'intervention a deux valeurs possibles**
 - ▶ $d = 0$ ne pas faire l'objet de l'intervention
 - ▶ $d = 1$ faire l'objet de l'intervention
- ▶ En statistique agricole : semer une variété plutôt qu'une autre ; en sciences médicales : utiliser un traitement plutôt qu'un autre ; en sciences sociales : à définir selon les besoins.
- ▶ **Cas généralisable** à des interventions plus compliquées !

Modèle causal de Neyman-Rubin (Splawa-Neyman, Dabrowska, and Speed (1990); Rubin (1974)) : variable d'intérêt

- ▶ On s'intéresse à une certaine **variable d'intérêt** Y qui doit quantifier les effets de l'intervention
 - ▶ en statistique agricole : les rendements agricoles
 - ▶ en sciences médicales : la survie des patients, leur guérison
 - ▶ en sciences sociales : ce dont on a besoin
- ▶ Pour chaque individu de la population on peut donner un sens aux **valeurs potentielles** de la variable :
 - ▶ $Y_i(0)$ la valeur si i ne faisait pas l'objet de l'intervention
 - ▶ $Y_i(1)$ la valeur si i faisait l'objet de l'intervention

Modèle causal de Neyman-Rubin (Splawa-Neyman, Dabrowska, and Speed (1990); Rubin (1974)) : effet causal

- ▶ L'**effet causal** de l'intervention sur l'individu i : $Y_i(1) - Y_i(0)$
 - ▶ Peut varier d'un individu à l'autre → **effets causaux hétérogènes**
 - ▶ Tout le monde ne réagit pas pareil à l'intervention
 - ▶ **Formalisme additif** facile à utiliser et d'une grande généralité
 - ▶ On peut faire des choix plus compliqués si nécessaire

Modèle causal de Neyman-Rubin (Splawa-Neyman, Dabrowska, and Speed (1990) ; Rubin (1974)) : des valeurs potentielles aux valeurs observées

- ▶ On n'observe que :
 - ▶ $Y_i = Y_i(0)$ si i ne fait pas l'objet de l'intervention
 - ▶ $Y_i = Y_i(1)$ si i fait l'objet de l'intervention
- ▶ ***Les effets causaux individuels ne peuvent jamais être observés*** (problème fondamental de l'inférence causale, cf supra)

Une solution au problème fondamental de l'inférence causale

- ▶ On ne peut jamais rien dire sur les effets causaux individuels qui soit empiriquement testable
- ▶ Mais on peut parfois dire des choses sur les **effets causaux moyens**
- ▶ C'est une solution statistique au problème

Rappel de probabilités : notion d'espérance et d'espérance conditionnelle

- ▶ Schématiquement : **espérance** ($\mathbb{E}[Y]$) = moyenne dans la population vs. **moyenne empirique** = moyenne dans l'échantillon
- ▶ **Loi des grands nombres** : quand l'échantillon est assez grand la seconde tend vers la première
- ▶ **Espérance conditionnelle** ($\mathbb{E}[Y | X = x]$) : moyenne dans la population pour un groupe défini par la valeur d'une certaine variable
 - ▶ dans la strate définie par $X = x$

Notions d'effets causaux moyens

- ▶ Effets causaux moyens **sur toute la population** (ATE) $\mathbb{E}[Y_i(1) - Y_i(0)]$
- ▶ Effets causaux moyens **sur ceux qui ont fait l'objet de l'intervention** (ATT) $\mathbb{E}[Y_i(1) - Y_i(0) \mid D_i = 1]$
- ▶ Effets causaux moyens **sur ceux qui n'ont pas fait l'objet de l'intervention** (ATU) $\mathbb{E}[Y_i(1) - Y_i(0) \mid D_i = 0]$

Comment identifier les effets d'une intervention dans une expérience aléatoire contrôlée ?

- ▶ Supposez que vous disposez de données issues d'une **expérience aléatoire contrôlée**, telles que pour chaque individu vous connaissez son statut vis-à-vis de l'intervention (a-t-il fait l'objet de l'intervention ou non) et la variable d'intérêt
- ▶ Pouvez-vous **identifier les effets causaux moyens** de l'intervention ?
- ▶ De quelle façon ?

Comment identifier les effets d'une intervention dans une expérience naturelle ?

- ▶ Supposez que vous disposez de données issues d'une **expérience naturelle**, telles que pour chaque individu vous connaissez son statut vis-à-vis de l'intervention (a-t-il fait l'objet de l'intervention ou non) et la variable d'intérêt
- ▶ Pouvez-vous **identifier les effets causaux moyens** de l'intervention ?
- ▶ De quelle façon ?

Interprétation causale des comparaisons simples

- ▶ Elle n'est garantie que pour les **expériences aléatoires contrôlées** et les **expériences naturelles**
- ▶ Interpréter de façon causale la différence moyenne entre les individus qui ont fait l'objet d'une intervention et les autres, c'est dire que **la situation que l'on étudie peut s'assimiler à une expérience aléatoire contrôlée** ou à une expérience naturelle (*as good as random*)

Remarque : hypothèses implicites du modèle de Neyman-Rubin

- ▶ **Stabilité des individus entre les mondes contrefactuels** : il faut que considérer le même individu i dans les deux situations hypothétiques ait un sens, et que la valeur $Y_i(d)$ ait un sens dans les deux cas
 - ▶ OK pour la statistique agricole et les sciences médicales
 - ▶ En sciences sociales il faut parfois faire attention ! → e.g. salaire des chômeurs, résultat des entreprises non-crées etc.
- ▶ Il faut que **ce qui arrive à i ne dépende pas de ce qui arrive à $j \neq i$**
 - ▶ ~ OK en statistique agricole si les parcelles ne sont pas trop proches
 - ▶ Pas toujours évident en sciences médicales ou sociales
- ▶ Il y a des techniques pour gérer les deux problèmes → sujet plus avancé, un peu abordé dans le support écrit

Pour commencer avec le contrôle des facteurs confondants : les admissions à Berkeley sont-elles biaisées selon le genre ?

Un exercice empirique

- ▶ Les données stockées dans `UBCadmissions`, accessibles par le package `datasets` représentent de façon agrégée les décisions d'admission en *graduate school* à Berkeley en 1973 (Bickel, Hammel, and O'Connell (1975))
- ▶ Quel est l'**écart de taux d'admission entre hommes et femmes** ? Cet écart a-t-il une interprétation causale ?
- ▶ Quel est le département pour lequel l'écart est le plus grand ? Combien vaut l'écart de taux d'admission pour ce département ?
- ▶ Que faut-il en conclure ?

Les femmes sont bien moins souvent admises que les hommes

```
library(datasets)
library(data.table)

sexbias_dat<-data.table(UCBAdmissions)

#On compare la part d'admis parmi les candidats selon le sexe
sexbias_dat[,
  list(part=sum(as.numeric(Admit=="Admitted")*
                N)/
        sum(N)*
        100),
  by="Gender"]
```

```
##      Gender      part
## 1:   Male 44.51877
## 2: Female 30.35422
```


Les choses sont très différentes si l'on regarde département par département

*#On compare la part d'admis parmi les candidats selon le sexe pour chaque
département*

```
sexbias_dat_par_dept<-  
  sexbias_dat[,  
    list(ecart_taux_admission=  
      (sum(as.numeric(Admit=="Admitted")*  
        as.numeric(Gender=="Female")*  
        N)/  
      sum(as.numeric(Gender=="Female")*N)-  
      sum(as.numeric(Admit=="Admitted")*  
        as.numeric(Gender=="Male")*  
        N)/  
      sum(as.numeric(Gender=="Male")*N))*  
      100),  
    by="Dept"]
```


Les choses sont très différentes si l'on regarde département par département

*#On compare la part d'admis parmi les candidats selon le sexe pour chaque
département*

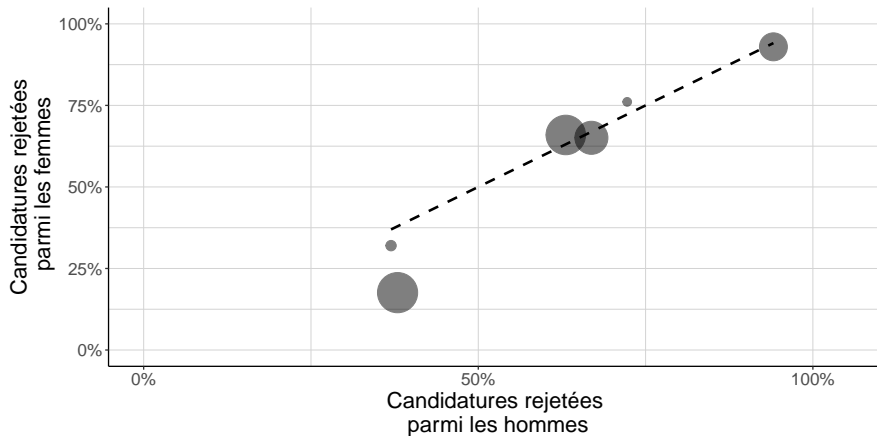
sexbias_dat_par_dept

##	Dept	ecart_taux_admission
## 1:	A	20.346801
## 2:	B	4.964286
## 3:	C	-2.858996
## 4:	D	1.839808
## 5:	E	-3.830116
## 6:	F	1.140000

Les femmes sont plus nombreuses à candidater aux départements les plus sélectifs



La sélectivité de chaque département n'est pas très différente pour les femmes et pour les hommes, ou bien en faveur des femmes



Que faut-il en tirer ?

- ▶ Les résultats sont **très différents** selon que l'on fait la comparaison sur UC Berkeley dans son ensemble ou département par département
- ▶ Pour faire une interprétation causale de ces comparaisons, il faut imaginer deux expériences aléatoires contrôlées différentes l'une de l'autre
 - ▶ avant que la candidature parvienne à l'université, on manipule aléatoirement le dossier pour qu'il semble provenir d'un homme ou d'une femme, **avec une probabilité qui est la même pour toutes les candidatures soumises à l'université**
 - ▶ avant que la candidature parvienne à l'université, on manipule aléatoirement le dossier pour qu'il semble provenir d'un homme ou d'une femme, **avec une probabilité qui est la même pour toutes les candidatures soumises à un département, mais qui varie d'un département à l'autre de l'université**
- ▶ Parce que la part de candidatures adressées par des femmes varie beaucoup d'un département à l'autre, **seule la deuxième solution est compatible avec les données collectées**

Que faut-il en tirer ?

- ▶ L'interprétation causale de ces comparaisons fait donc l'**hypothèse que chaque département fait séparément sa propre expérience aléatoire contrôlée**
- ▶ Peut-on **identifier les effets causaux moyens du sexe** sur l'admission dans ces conditions ?
 - ▶ Utiliser les données pour estimer le **taux contrefactuel d'admission pour les femmes** si leurs dossiers étaient perçus comme des dossiers envoyés par des hommes
 - ▶ Utiliser les données pour estimer les **effets causaux moyens du sexe sur l'admission**

Identifier les effets causaux moyens du sexe sur l'admission

- ▶ Pour estimer les effets causaux moyens du sexe sur l'admission, on fait des **comparaisons à l'intérieur de chaque département** :
 - ▶ on dit que l'on **conditionne sur la variable de département**
 - ▶ c'est-à-dire qu'on compare entre eux seulement des dossiers adressés au même département
 - ▶ ce que l'on fait en considérant les taux d'admission dans des strates définies par les valeurs de la variable de département (\sim espérance conditionnelle)
- ▶ Puis on peut **réagréger** tout ça au niveau de UC Berkeley prise en entier (avec des poids bien choisis)

Les deux hypothèses clés

- ▶ **Hypothèse d'indépendance conditionnelle** : à l'intérieur de chaque département, tout se passe comme si on était devant une expérience aléatoire contrôlée ou une expérience naturelle
 - ▶ Le sexe est indépendant des valeurs potentielles de la décision d'admission, conditionnellement au département
- ▶ **Hypothèse de support commun** : la part de dossiers envoyés par des femmes dans chaque département est différente de 0 et 100%
 - ▶ sinon on ne peut plus définir la différence entre femmes et hommes dans le département !

Estimer le taux contrefactuel d'admission pour les femmes si leurs dossiers étaient perçu comme des dossiers envoyés par des hommes

*#Il faut simplement sommer les taux d'admission des hommes dans les
différents départements, avec des poids proportionnels au nombre de
candidatures adressées à chaque département par des femmes.*

```
taux_contrefactuel<-100*(  
  1-  
    sexbias_dat_dpt[,  
      list(taux_contrefactuel=  
        sum(selectivite_hommes*  
          part_femmes*  
          taille)/  
        sum(part_femmes*  
          taille))])  
taux_contrefactuel
```

```
##      taux_contrefactuel  
## 1:      30.24544
```

Estimer les effets causaux moyens du sexe sur l'admission : ATE

*#Pour l'effet causal moyen sur toute la population, il faut faire la moyenne
des différences entre les taux d'admission des femmes et des hommes dans
chaque département avec des poids proportionnels au nombre total de
candidatures reçues*

```
ATE<-sexbias_dat_dpt[,  
                      list(ATE=sum(100*(  
                        (1-selectivite_femmes)-  
                        (1-selectivite_hommes))*  
                        taille)/  
                        sum(taille))]
```

ATE

```
##          ATE
```

```
## 1: 4.26368
```

Estimer les effets causaux moyens du sexe sur l'admission : ATT

*#Pour l'effet causal moyen chez les femmes, il faut utiliser des poids
proportionnels au nombre de candidatures féminines reçues par chaque
département*

```
ATT<-sexbias_dat_dpt[,  
                      list(ATT=sum(100*(  
                        (1-selectivite_femmes)-  
                        (1-selectivite_hommes))*  
                        taille*  
                        part_femmes)/  
                        sum(taille*  
                            part_femmes))]
```

ATT

ATT

1: 0.108779

Estimer les effets causaux moyens du sexe sur l'admission : ATU

*#Pour l'effet causal moyen chez les hommes, il faut utiliser des poids
proportionnels au nombre de candidatures masculines reçues par chaque
département*

```
ATU<-sexbias_dat_dpt[,  
                      list(ATU=sum(100*(  
                        (1-selectivite_femmes)-  
                        (1-selectivite_hommes))*  
                        taille*  
                        (1-part_femmes))/  
                        sum(taille*  
                          (1-part_femmes))))]
```

ATU

```
##           ATU
```

```
## 1: 7.096918
```

Estimer les effets causaux moyens : une petite question

- ▶ Si on connaît l'**ATT** et l'**ATU**, sait-on en déduire l'**ATE** ?

Estimer les effets causaux moyens : une petite question

*#On peut vérifier que l'ATE est bien égal à la moyenne pondérée de l'ATT
et de l'ATU avec des poids égaux aux parts respectives des deux
sous-populations dans l'ensemble des candidatures*

```
effectifs_sexe<-sexbias_dat[,  
                           list(effectif=sum(N)),  
                           by="Gender"]  
  
ATE_calcul_alternatif<-  
  (effectifs_sexe[Gender=="Male"]$effectif*ATU$ATU+  
    effectifs_sexe[Gender=="Female"]$effectif*ATT$ATT)/  
  (sum(effectifs_sexe$effectif))  
all.equal(as.numeric(ATE),  
          ATE_calcul_alternatif)
```

```
## [1] TRUE
```

Appuyer graphiquement l'hypothèse d'indépendance
conditionnelle

Peut-on croire à l'hypothèse d'indépendance conditionnelle ?

- ▶ L'hypothèse d'indépendance conditionnelle assure que l'on peut identifier les effets causaux en raisonnant à l'intérieur de sous-populations
 - ▶ ou ce qui revient au même **à l'intérieur de strates définies par la valeur de certaines variables**
- ▶ Si on sait que c'est vrai parce que l'on a fait une **expérience aléatoire stratifiée**, c'est-à-dire une expérience aléatoire contrôlée dans chacune de ces strates, ou que l'on sait qu'on regarde une expérience naturelle quand on raisonne à l'intérieur d'une strate, alors on a gagné
- ▶ Mais **c'est rarement le cas !** Comment faire alors ?
- ▶ En particulier la crédibilité de l'hypothèse d'indépendance conditionnelle dépend de la définition des strates, c'est-à-dire encore du choix des variables sur lesquelles on conditionne → **comment choisir ?**


Approches graphiques de la causalité

- ▶ Approches qui ont une histoire longue mais dont les **développements récents doivent beaucoup à Judea Pearl (informaticien)**
- ▶ Permet de **dépasser les discussions un peu heuristiques et les arguments un peu relâchés** sur le choix des variables de conditionnement et la crédibilité de l'hypothèse d'indépendance conditionnelle

Approches graphiques de la causalité

- ▶ **Approche quantitative mais pas fondée sur les données**
- ▶ L'idée :
 - ▶ **représenter graphiquement** la question que l'on se pose
 - ▶ cette représentation graphique est l'objet d'un **traitement informatique** qui indique
 - ▶ **s'il existe (au moins) un ensemble des variables de conditionnement** tel que l'hypothèse d'indépendance conditionnelle est crédible
 - ▶ **quelles variables** appartiennent à cet ensemble (ces ensembles)
- ▶ **Package** ggdag disponible pour R

Représentation graphique de la causalité : un exemple (Jacques and Noël (2022))



Les ingrédients de la représentation graphique

- ▶ Des **nœuds** qui correspondent aux différentes variables du problème
- ▶ Des **flèches** qui représentent le flot de causalité d'une variable à l'autre
- ▶ Une variable est la **variable d'intervention**
- ▶ Une variable est le **résultat** ou la **variable d'intérêt**

Coder l'objet qui génère la représentation graphique dans ggdag

```
graph_jacques<-dagify(SantePub~Austerite+AppartParti+SystemeSante+ConditEco,  
  #Pour chaque nœud auquel aboutit au moins une flèche,  
  # on recense d'où partent toutes ces flèches  
  Austerite~AppartParti+SystemeSante+ConditEco,  
  exposure = "Austerite",  
  #La variable qui correspond à l'intervention dont on  
  # souhaite étudier les effets  
  outcome = "SantePub",  
  #La variable qui correspond aux conséquences que l'on  
  # voudrait pouvoir mesurer  
  labels = c("SantePub"="Santé publique",  
    "Austerite"="Austérité",  
    "AppartParti"="Appartenance \npartisane",  
    "SystemeSante"="Système de \nsanté",  
    "ConditEco"="Conditions \néconomiques"))
```

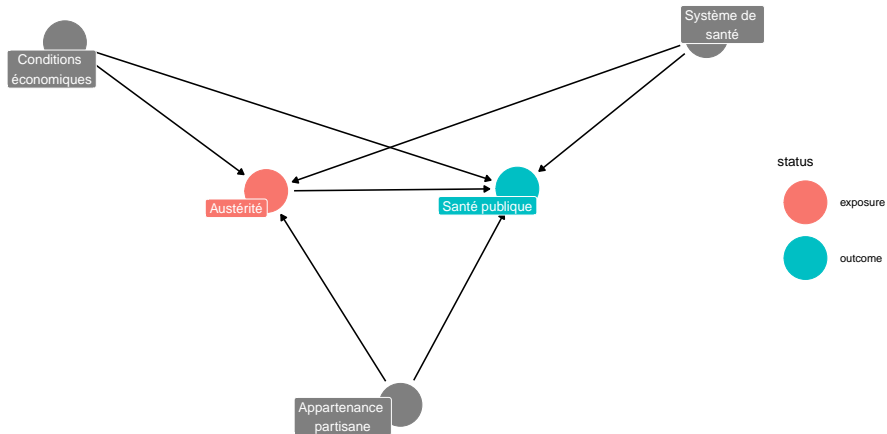
La marche à suivre

- ▶ Pour chaque variable on recense simplement **toutes les variables, observées ou non, qui doivent apparaître comme cause directe de celle-ci**
 - ▶ ce n'est pas une décision fondée sur les données dont on dispose
 - ▶ c'est une **décision essentiellement théorique** fondée sur :
 - ▶ la théorie sociologique de l'objet particulier que l'on étudie
 - ▶ la littérature antérieure disponible
- ▶ La **représentation graphique** est ensuite générée par la fonction `ggdag`
 - ▶ Ici j'ai rajouté quelques améliorations pour la rendre visuellement plus agréable, voir le site pour les détails du code

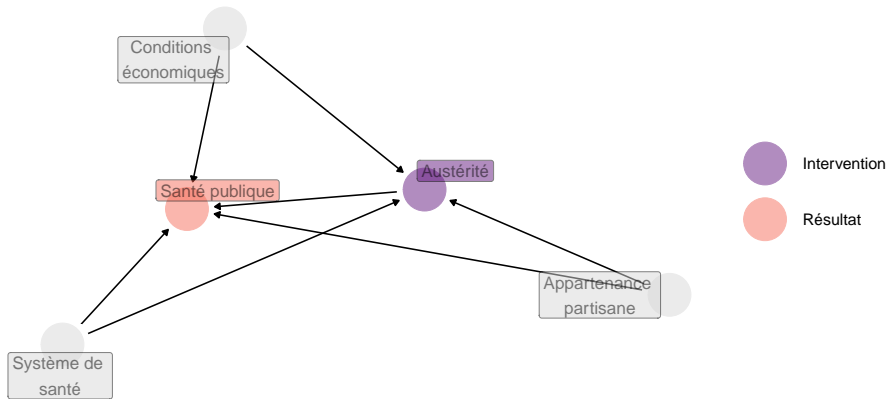
Ce que donne la fonction ggdag

```
graph_jacques_obtenu_par_ggdag<-  
  ggdag_status(graph_jacques,  
               text=FALSE,  
               use_labels = "label",  
               label_size=5)+  
  #J'utilise en fait ggdag_status qui met distingue la variable d'intérêt  
  # et l'intervention  
  theme_void()
```

Ce que donne la fonction ggdag



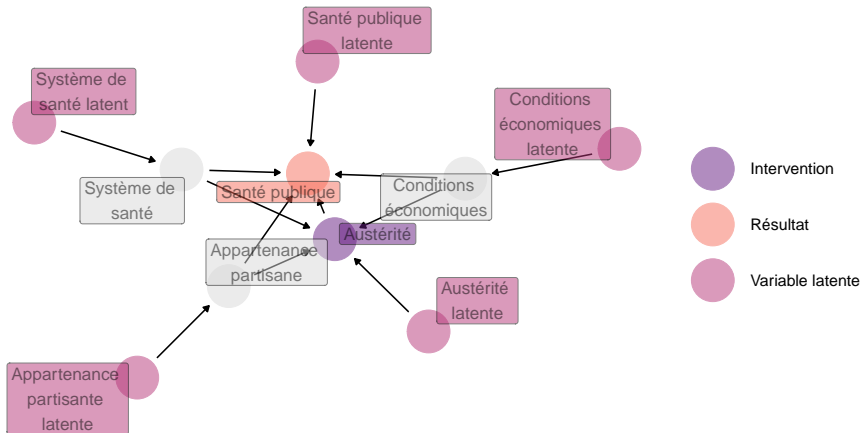
Avec un peu de travail supplémentaire



Représenter les variables inobservées ?

- ▶ Ici le graphe ne représente pas de **variables inobservées**
- ▶ Dans l'approche proposée par Pearl (2009), on garde en général **implicites** les variables inobservées ("latentes") *qui ne sont causes que d'une seule variable*
 - ▶ Chaque variable observée est toujours supposée dépendre d'*une variable inobservée, indépendante de toutes les autres variables du problème*, en plus de toutes celles représentées par les flèches qui aboutissent au nœud qui lui correspond
- ▶ On peut choisir de les représenter **sans changer la signification** du graphe du point de vue des outils que l'on va mobiliser ensuite
- ▶ Représenter toutes les variables inobservées qui n'aboutissent chacune qu'à une seule variable observée est parfois appelé **magnification**

Ce graphe est strictement équivalent au précédent mais beaucoup plus difficile à lire



Que signifient ces flèches ?

- ▶ **Pas d'hypothèse de constance ou de linéarité des effets !** Relation aussi générale qu'il est possible de l'être → rejoint l'hypothèse d'effets causaux hétérogènes chez Rubin
- ▶ Quand on code `SantePub~Austerite+AppartParti+SystemeSante+ConditEco`, on dit qu'il existe :
 - ▶ une fonction (inconnue) $f^{SantePub}$
 - ▶ une variable latente $LatSantePub$ indépendante de toutes les autres variables, observées ou latentes telles que :
$$SantePub = f^{SantePub}(Austerite, AppartParti, SystemeSante, ConditEco; LatSantePub)$$

Le champ auquel s'appliquent ces techniques : les graphes acycliques

- ▶ Un graphe est **cyclique** si en partant d'un nœud et en suivant successivement des flèches, dans le bon sens, on pourrait revenir à ce nœud
- ▶ **Les graphes cycliques ne sont pas couverts par les techniques fondées sur les représentations graphiques**
- ▶ Cela exclut le cas de la **simultanéité** (X cause Y qui cause X)

Pouvez-vous proposer des exemples généraux de graphes cycliques ?


- ▶ Pas besoin de spécifier des noms de variables, **c'est seulement la forme qui importe**
- ▶ Avec 2 ou 3 nœuds pour commencer
- ▶ Construisez les à partir des fonctions du package ggdag

Exemples de graphes cycliques : avec deux variables

```
library(ggdag)

cycle2<-dagify(A~B,
               B~A)
```


Exemples de graphes cycliques : avec deux variables



Exemples de graphes cycliques : avec trois variables

```
cycle3<-dagify(A~B,  
               B~C,  
               C~A)
```

Exemples de graphes cycliques : avec trois variables



Un peu de vocabulaire sur ces représentations graphiques

- ▶ **Graphe acyclique orienté** (*directed acyclic graph* en anglais)
- ▶ Vocabulaire de la **parenté** appliquée aux nœuds / variables
- ▶ **Chemin** : succession de flèches (pas nécessairement dans le même sens) pour aller d'une variable à une autre
- ▶ **Chemin orienté** : toutes les flèches vont dans le même sens


Quel est le graphe d'une expérience naturelle ?

- ▶ Supposez que vous étudiez une **expérience naturelle**
- ▶ Par exemple Godechot (2016) : pour les recrutements à l'EHESS, premier classement des dossiers effectué par une commission tirée au sort à laquelle peut appartenir le directeur de thèse des candidats
- ▶ Quel est le graphe à considérer dans cette situation ?
- ▶ Construisez le à l'aide du package `ggdag`

Quel est le graphe d'une expérience naturelle ?

```
graph_godechot<-dagify(Admissib~DirThese,  
  #Pour chaque nœuds auquel aboutit au moins une flèche,  
  # on recense d'où partent toutes ces flèches  
  exposure = "DirThese",  
  #La variable qui correspond à l'intervention dont on  
  # souhaite étudier les effets  
  outcome = "Admissib",  
  #La variable qui correspond aux conséquences que l'on  
  # voudrait pouvoir mesurer  
  labels = c("DirThese"="Directeur de thèse tiré au sort",  
             "Admissib"="Admissibilité"))  
  #Des labels pour rendre les choses plus lisibles
```

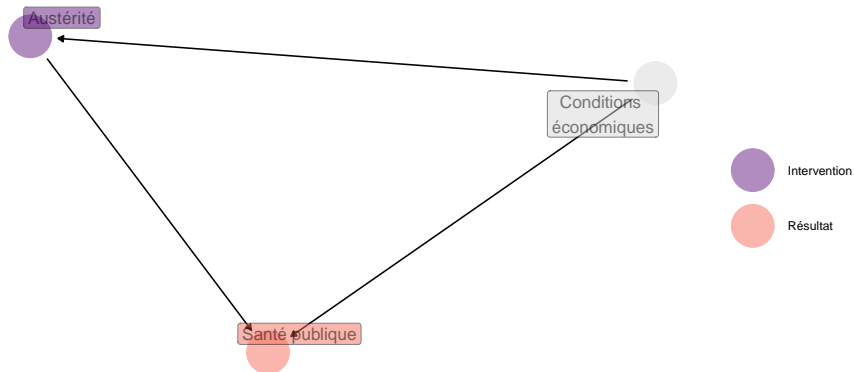
Quel est le graphe d'une expérience naturelle ?



Graphe d'une expérience naturelle : justification

- ▶ Bien entendu l'admissibilité dépend d'énormément des facteurs différents
- ▶ Mais la commission qui prend la décision est tirée au sort on sait que la présence du directeur de thèse dans le jury est indépendante de tous ces autres facteurs
- ▶ On peut tous les **résumer en une variable latente indépendante** de toutes les autres variables du problème
- ▶ On n'a en fait **pas besoin de représenter explicitement** cette variable latente

Pourquoi conditionner sur une variable observable? Un graphe simplifié à partir de Jacques and Noël (2022)



Pourquoi conditionner sur une variable observable ? Un graphe simplifié à partir de Jacques and Noël (2022)

- ▶ Comment ce graphe doit-il être transformé si on raisonne **à l'intérieur d'une strate** de pays qui font tous face aux mêmes conditions économiques ?
- ▶ En d'autres termes si l'on **conditionne** sur les conditions économiques ?

Pourquoi conditionner sur une variable observable? Quand on raisonne à conditions économiques identiques entre pays



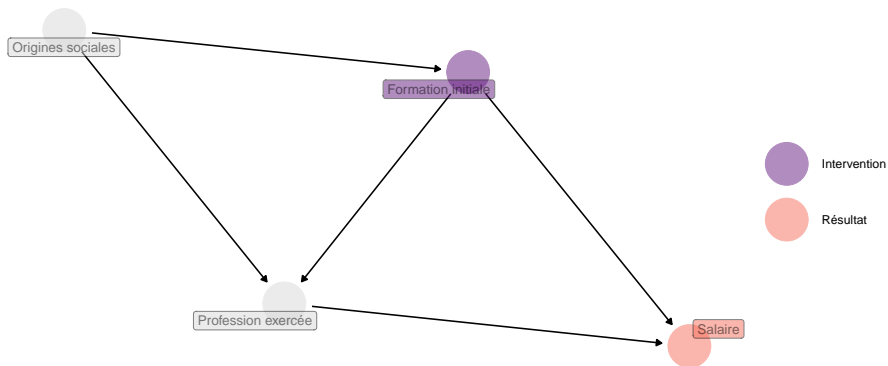
Pourquoi conditionner sur une variable observable ? Quand on raisonne à conditions économiques identiques entre pays

- ▶ Les conditions économiques **ne varient pas d'un pays à l'autre**
- ▶ Il n'y a donc pas de sens à les faire figurer comme cause de l'austérité
- ▶ Ni comme cause du niveau et de la structure de la dépense de santé publique
- ▶ On peut enlever toutes les flèches qui partent de cette variable
- ▶ Pour autant qu'on s'intéresse seulement à l'austérité et à la dépense de santé publique, **c'est comme si on regardait une expérience naturelle**
- ▶ Autrement dit : **le graphe de départ équivaut à l'hypothèse d'indépendance conditionnelle**
- ▶ Il justifie donc de conditionner sur les conditions économiques pour **identifier les effets causaux moyens** de l'austérité sur le niveau et la structure de la dépense de santé publique

Encore un peu de vocabulaire : les portes de sortie

- ▶ **Porte de sortie** (*backdoor* en anglais) : chemin *non-orienté* qui lie l'intervention et la variable d'intérêt, et dont une extrémité est **une flèche qui débouche sur l'intervention**
- ▶ C'est donc un chemin qui aboutit à la variable d'intérêt mais qui **contient une des causes de l'intervention**
- ▶ Ici le chemin $\text{Austérité} \leftarrow \text{Conditions économiques} \rightarrow \text{Santé publique}$ est une porte de sortie
- ▶ Conditionner sur les conditions économiques, c'est-à-dire comparer des pays connaissant les mêmes conditions économiques permet de **bloquer la porte de sortie**
- ▶ C'est-à-dire de neutraliser la part de la corrélation entre austérité et dépense de santé publique qui vient du fait qu'elles ont une cause commune
- ▶ Cela permet en définitive d'identifier les effets causaux moyens de l'austérité sur la dépense de santé publique

Faut-il toujours conditionner sur les caractéristiques observables ? Un exemple hypothétique



Faut-il toujours conditionner sur les caractéristiques observables ?

- ▶ Ici on a **trois chemins** qui lient l'intervention et la variable d'intérêt
 - ▶ le **chemin direct** : Formation initiale \longrightarrow Salaire
 - ▶ la **porte de sortie** : Formation initiale \longleftarrow Origines sociales \longrightarrow Profession exercée \longrightarrow Salaire
 - ▶ le chemin Formation initiale \longrightarrow Profession exercée \longrightarrow Salaire
- ▶ On appelle ce dernier chemin une **chaîne de médiation**
 - ▶ un chemin orienté qui part de l'intervention et aboutit à la variable d'intérêt

Faut-il toujours conditionner sur les caractéristiques observables ? Non : ne pas bloquer les chaînes de médiation


- ▶ Si on veut connaître les effets causaux moyens de l'intervention, **on ne veut surtout pas bloquer les chaînes de médiation !**
 - ▶ C'est une question différente et différente de savoir quelle part de ces effets causaux passe par quel chemin → **analyse de médiation**, sujet non-traité ici mais important pour étudier les mécanismes sociologiques mis en jeu
- ▶ Dans le cas présent : on va conditionner sur les origines sociales mais **pas sur la profession exercée**
- ▶ Typiquement ici conditionner sur la profession exercée conduirait à sous-estimer les effets causaux moyens de la formation initiale sur le salaire

Faut-il toujours conditionner sur les caractéristiques observables ?


L'exemple des violences policières aux Etats-Unis

- ▶ Débat important sur les violences policières et la persistance du racisme aux Etats-Unis
- ▶ Question essentielle : l'usage de la force par la police étatsunienne est-il influencé par des biais racistes ?
 - ▶ C'est une **question causale** : dans la rencontre entre un policier et un civil, la perception du civil par le policier comme relevant d'une catégorie ethno-raciale ou d'une autre conduit-elle à des décisions différentes
- ▶ Knox, Lowe, and Mummolo (2020) synthétisent une longue littérature qui montre que, parmi les civils faisant l'objet d'un contrôle, **la fréquence d'usage de la force n'est pas plus grande contre des civils Noirs américains que contre des civils Blancs**
- ▶ Est-ce une bonne façon d'identifier ces effets causaux moyens ?

Faut-il toujours conditionner sur les caractéristiques observables ?
L'exemple des violences policières aux Etats-Unis : ce que l'on croit qu'on fait



Faut-il toujours conditionner sur les caractéristiques observables ?
L'exemple des violences policières aux Etats-Unis : ce que l'on fait vraiment



Faut-il toujours conditionner sur les caractéristiques observables ?

L'exemple des violences policières aux Etats-Unis : les conséquences du conditionnement sur le contrôle

- ▶ Si **des biais racistes sont également présents dans la décision de contrôler**
 - ▶ c'est-à-dire si pour des activités également susceptibles de mener à un contrôle, les Noirs sont bien plus souvent contrôlés
- ▶ Alors la population des **civils faisant l'objet d'un contrôle** comprend (grossièrement) :
 - ▶ des Blancs dont l'activité semblerait suspecte quelle que soit la catégorie raciale
 - ▶ des Noirs dont l'activité semblerait suspecte quelle que soit la catégorie raciale
 - ▶ des Noirs dont l'activité ne paraîtrait pas suspecte s'ils étaient Blancs

Faut-il toujours conditionner sur les caractéristiques observables ?

L'exemple des violences policières aux Etats-Unis : les conséquences du conditionnement sur le contrôle

- ▶ Au sein d'un groupe ainsi constitué il est attendu que l'usage de la force ne soit pas plus fréquent contre les Noirs que contre les Blancs
 - ▶ mais **cela ne signifie en rien que l'usage de la force n'est pas biaisé racialement**
- ▶ Il faudrait donc ne pas conditionner !
 - ▶ En d'autres termes **travailler sur toute la population des interactions entre policiers et civils**, et pas seulement sur celles qui conduisent à un contrôle
- ▶ Pas forcément faisable en pratique : voir l'article de Knox, Lowe, and Mummolo (2020) pour des solutions statistiques (sujet non-traité ici)

Faut-il toujours conditionner sur les caractéristiques observables ? Non : ne pas créer de biais de collision

- ▶ Ici le problème vient du fait que l'on conditionne sur la **fourchette inversée**
Minorité \longrightarrow Contrôle \longleftarrow Activité suspecte
- ▶ Ce conditionnement génère une corrélation qui n'a pas d'interprétation causale entre la catégorie raciale et l'activité potentiellement suspecte
- ▶ Cette corrélation non-causale est parfois appelée **biais de collision** (*collider bias* en anglais)
- ▶ **Il est très important de l'éviter !**

Comment choisir les variables de conditionnement ? Un premier bilan

- ▶ **Conditionner sur une ou plusieurs variables observables** permet parfois d'**identifier des effets causaux moyens**
- ▶ Conditionner sur certaines variables observables peut au contraire **empêcher cette identification**, en particulier si :
 - a. ces variables sont des **médiateurs** de l'effet de l'intervention sur la dimension d'intérêt
 - b. conditionner sur ces variables crée une corrélation entre des variables non-apparentées, parce que l'on fait apparaître ainsi un **biais de collision**

Stratégie *backdoor*

- ▶ C'est la stratégie qui permet de **choisir l'ensemble des variables de conditionnement**
- ▶ Un tel ensemble (*éventuellement vide*) de variables doit à la fois (i) bloquer toutes les **portes de sortie** qui débouchent sur l'intervention et (ii) ne bloquer aucune des **chaînes de médiation** qui vont de l'intervention au résultat étudié.
- ▶ Une porte de sortie débouchant sur l'intervention est bloquée si :
 - ▶ elle contient une flèche qui aboutit à une des variables sur laquelle on conditionne
 $A \longrightarrow X$
 - ▶ elle contient deux flèches qui partent d'une variable sur laquelle on conditionne
 $A \longleftarrow X \longrightarrow B$
 - ▶ elle contient une fourchette inversée $A \longrightarrow Z \longleftarrow B$ telle que ni Z ni aucun de ses descendants n'appartienne à l'ensemble des variables sur lesquelles on conditionne

Stratégie *backdoor* : quelques remarques

- ▶ **Solution parfois multiple** → plusieurs choix d'ensemble de variables sur lesquelles il est possible de conditionner pour identifier des effets causaux
- ▶ **Pas toujours besoin de conditionner** → l'ensemble vide est solution et la comparaison des individus selon les valeurs prises par la variable représentant l'intervention suffit à en identifier les effets causaux moyens
- ▶ **Pas toujours de solution** → l'ensemble des solutions peut être vide

⚠ les deux derniers points ne veulent pas dire la même chose

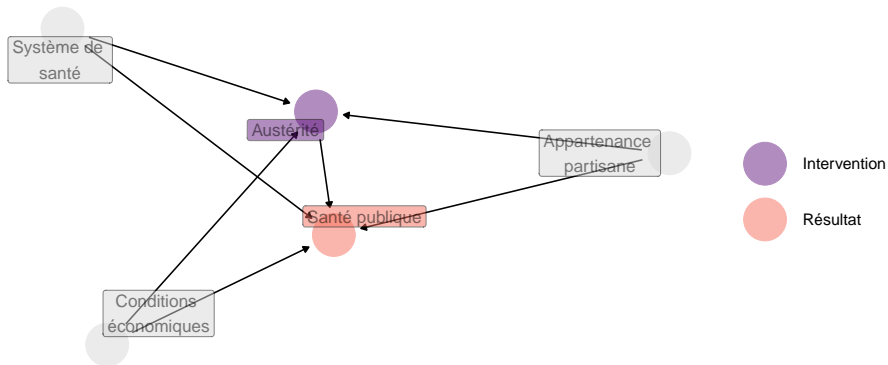
Stratégie *backdoor* : en pratique ?

- ▶ **Un jeu de règles simples** mais fastidieux à appliquer quand on est dans un cas un peu complexe
 - ▶ On aurait éventuellement besoin de vérifier tous les ensembles de variables de conditionnement possibles pour vérifier lesquels respectent ces règles et peuvent être retenus
- ▶ Pourquoi des informaticiens se sont intéressés à l'application de ce formalisme aux relations causales ?
 - ▶ **Les graphes orientés sont un objet très usuel pour les informaticiens**
 - ▶ Développement d'**algorithmes efficaces** permettant de déterminer automatiquement les solutions possibles au problème à partir de la donnée du graphe
 - ▶ On peut les invoquer avec le **package** `ggdag` !

La fonction `dag_adjustment_sets` du package `ggdag`

- ▶ **Prend en entrée un graphe**
- ▶ **Renvoie l'ensemble des solutions *minimales* du problème**
 - ▶ Ces solutions sont elles-mêmes des ensembles !
- ▶ **Solutions minimales ?**
 - ▶ Minimales au sens de l'inclusion
 - ▶ Il n'existe pas d'ensemble de variables de conditionnement qui soit strictement inclus dans une solution minimale et qui soit solution du problème
 - ▶ Intéressant d'avoir des solutions minimales en vue de l'estimation → discussion de la semaine prochaine : **plus on a de variables à considérer plus la mise en pratique du conditionnement est difficile**

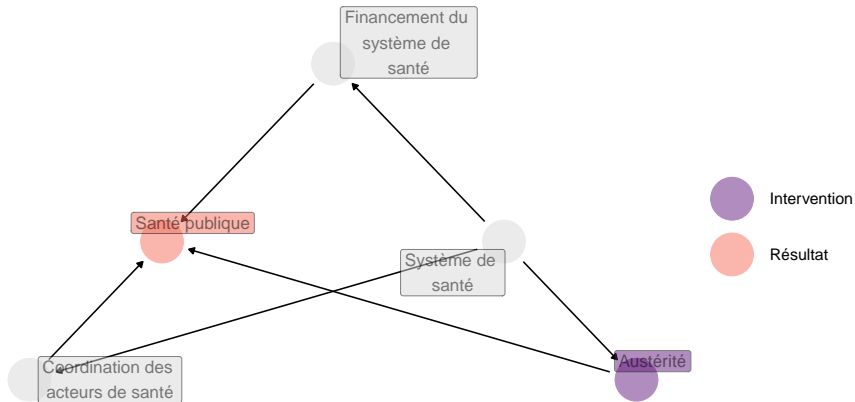
Le graphe tiré de Jacques and Noël (2022). Déterminer les solutions possibles à l'aide de dag_adjustment_sets



Le graphe tiré de Jacques and Noël (2022). Déterminer les solutions possibles à l'aide de dag_adjustment_sets

```
graph_jacques<-dagify(SantePub~Austerite+AppartParti+SystemeSante+ConditEco,  
  #Pour chaque nœuds auquel aboutit au moins une flèche,  
  # on recense d'où partent toutes ces flèches  
  Austerite~AppartParti+SystemeSante+ConditEco,  
  exposure = "Austerite",  
  #La variable qui correspond à l'intervention dont on  
  # souhaite étudier les effets  
  outcome = "SantePub")  
  #La variable qui correspond aux conséquences que l'on  
  # voudrait pouvoir mesurer  
  
  #On récupère un ensemble de variables de conditionnement  
  conditionner<-data.table(dag_adjustment_sets(graph_jacques)[[1]])  
  levels(factor(conditionner$set))  
  
## [1] "{AppartParti, ConditEco, SystemeSante}"
```

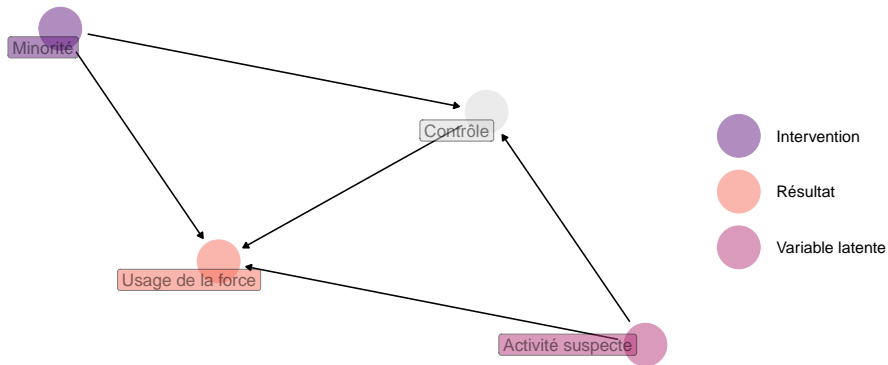
Un exemple inspiré de Jacques and Noël (2022). Déterminer les solutions possibles à l'aide de dag_adjustment_sets



Un exemple inspiré de Jacques and Noël (2022). Déterminer les solutions possibles à l'aide de dag_adjustment_sets

```
graph_jacques_multiple<-  
  dagify(SantePub~Austerite+DiffFinanceSysSan+CoordActSante,  
        Austerite~SystemeSante,  
        DiffFinanceSysSan~SystemeSante,  
        CoordActSante~SystemeSante,  
        exposure = "Austerite",  
        outcome = "SantePub")  
  
#On récupère un ensemble d'ensembles de variables de conditionnement  
conditionner<-  
  data.table(dag_adjustment_sets(graph_jacques_multiple)[[1]])  
levels(factor(conditionner$set))  
  
## [1] "{CoordActSante, DiffFinanceSysSan}" "{SystemeSante}"
```


Un exemple inspiré de Knox, Lowe, and Mummolo (2020). Déterminer les solutions possibles à l'aide de dag_adjustment_sets



Un exemple inspiré de Knox, Lowe, and Mummolo (2020). Déterminer les solutions possibles à l'aide de `dag_adjustment_sets`

```
dag_race_force_complete<-dagify(force ~ race + suspicion + stop,  
                                stop ~ race + suspicion,  
                                exposure="race",  
                                outcome="force",  
                                latent="suspicion",  
                                labels=c("race"="Minorité",  
                                          "suspicion"="Activité suspecte",  
                                          "force"="Usage de la force",  
                                          "stop"="Contrôle"))  
  
#On récupère un ensemble d'ensembles de variables de conditionnement  
conditionner<-  
  data.table(dag_adjustment_sets(dag_race_force_complete)[[1]])  
levels(factor(conditionner$set))  
  
## [1] "{(Backdoor Paths Unconditionally Closed)}"
```


Un exemple fictif. Déterminer les solutions possibles à l'aide de `dag_adjustment_sets`



Un exemple fictif. Déterminer les solutions possibles à l'aide de dag adjustment sets

```
dag_fict<-dagify(Y ~D + U2 +X,  
                D~U1,  
                X~U1+U2,  
                exposure = "D",  
                outcome = "Y",  
                latent = c("U1","U2"))
```

#On récupère un ensemble de variables de conditionnement

```
conditionner<-data.table(dag_adjustment_sets(dag_fict)[[1]])
```

```
## Warning in dag_adjustment_sets(dag_fict): Failed to close backdoor paths. Comm
```

```
##           * graph is not acyclic
```

```
##           * backdoor paths are not closeable with given set of variables
```

```
##           * necessary variables are unmeasured (latent)
```

```
levels(factor(conditionner$set))
```

```
## [1] "{(No Way to Block Backdoor Paths)}"
```

Une conclusion pour aujourd'hui

- ▶ **Un concept à peu près opérationnel de causalité pour les sciences sociales quantitatives**
 - ▶ Conception **interventionniste** de la causalité
 - ▶ Place centrale de l'**expérience aléatoire contrôlée** et de l'**expérience naturelle**

Une conclusion pour aujourd'hui

- ▶ Définition raisonnable de ce que c'est que **contrôler de X**
 - ▶ **Conditionner** : comparer entre eux des individus qui ont la même valeur de X
 - ▶ Identifie les effets causaux moyens de l'intervention sous une **hypothèse d'indépendance conditionnelle**

Une conclusion pour aujourd'hui

- ▶ **Une approche graphique et algorithmique pour déterminer sur quelles variables on veut conditionner**
 - ▶ Bloquer les portes de sortie
 - ▶ Attention au biais de collision et aux chaînes de médiation

Au programme pour la semaine prochaine

- ▶ On sait sur quelles variables observables on veut conditionner
- ▶ En théorie conditionner a l'air très simple
- ▶ Mais en pratique. . .

Bibliographie

Bibliographie I

- Bickel, P. J., E. A. Hammel, and J. W. O'Connell. 1975. "Sex Bias in Graduate Admissions : Data from Berkeley." *Science* 187 (4175) : 398–404.
<https://doi.org/10.1126/science.187.4175.398>.
- Godechot, Olivier. 2016. "The Chance of Influence : A Natural Experiment on the Role of Social Capital in Faculty Recruitment." *Social Networks* 46 : 60–75.
<https://doi.org/https://doi.org/10.1016/j.socnet.2016.02.002>.
- Holland, Paul W. 1986. "Statistics and Causal Inference." *Journal of the American Statistical Association* 81 (396) : 945–60.
- Jacques, Olivier, and Alain Noël. 2022. "The Politics of Public Health Investments." *Social Science & Medicine* 309 : 115272.
<https://doi.org/https://doi.org/10.1016/j.socscimed.2022.115272>.

Bibliographie II

- Knox, Dean, Will Lowe, and Jonathan Mummolo. 2020. "Administrative Records Mask Racially Biased Policing." *American Political Science Review*.
https://www.cambridge.org/core/journals/american-political-science-review/article/administrative-records-mask-racially-biased-policing/66BC0F9998543868BB20F241796B79B8?utm_source=hootsuite/&utm_medium=twitter/&utm_term=/&utm_content=FirstView/&utm_campaign=PS.
- Pearl, Judea. 2009. *Causality*. Cambridge University Press.
- Piketty, Thomas. 2019. *Capital Et Idéologie*. Paris : Le Seuil.
- Rubin, Donald B. 1974. "Estimating Causal Effects of Treatments in Randomized and Nonrandomized Studies." *Journal of Educational Psychology* 66 (5) : 688.
- Splawa-Neyman, Jerzy, D. M. Dabrowska, and T. P. Speed. 1990. "On the Application of Probability Theory to Agricultural Experiments. Essay on Principles. Section 9." *Statistical Science* 5 (4) : 465–72.